



МИНОБРНАУКИ РОССИИ
федеральное государственное бюджетное образовательное
учреждение высшего образования
«Национальный исследовательский университет «МЭИ»

Институт

ИВТИ

Кафедра

ПМИИ

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
(бакалаврская работа)

Направление **01.03.02 Прикладная математика и информатика**
(код и наименование)

Направленность (профиль) **Математическое и программное**
обеспечение вычислительных машин и компьютерных сетей

Форма обучения **очная**
(очная/очно-заочная/заочная)

Тема: **Исследование и реализация методов интеллектуального**
анализа данных электрофизиологических исследований
с применением машинного обучения

Студент **А-05-17** **Горшков В.С.**
группа подпись фамилия и инициалы

Научный руководитель **д.т.н. профессор** **Еремеев А.П.**
уч. степень должность подпись фамилия и инициалы

Консультант **к.т.н. ст. преподаватель** **Ивлиев С.А.**
уч. степень должность подпись фамилия и инициалы

«Работа допущена к защите»

Зав. кафедрой **к.т.н. доцент** **Варшавский П.Р.**
уч. степень звание подпись фамилия и инициалы

Дата _____

Москва, 2021



МИНОБРНАУКИ РОССИИ
федеральное государственное бюджетное образовательное
учреждение высшего образования
«Национальный исследовательский университет «МЭИ»

Институт	ИВТИ
Кафедра	ПМИИ

ЗАДАНИЕ
НА ВЫПУСКНУЮ КВАЛИФИКАЦИОННУЮ РАБОТУ
(бакалаврскую работу)

Направление **01.03.02 Прикладная математика и информатика**
(код и наименование)

Направленность (профиль) **Математическое и программное**
обеспечение вычислительных машин и компьютерных сетей

Форма обучения **очная**
(очная/очно-заочная/заочная)

Тема: **Исследование и реализация методов интеллектуального**
анализа данных электрофизиологических исследований
с применением машинного обучения

Студент	A-05-17	Горшков В.С.
	группа	подпись фамилия и инициалы

Научный ру- ководитель	Д.Т.Н.	профессор	Еремеев А.П.
	уч. степень	должность	подпись фамилия и инициалы

Консультант	к.т.н.	ст.преподаватель	Ивлиев С.А.
	уч. степень	должность	подпись фамилия и инициалы

Зав. кафедрой	к.т.н.	доцент	Варшавский П.Р.
	уч. степень	звание	подпись фамилия и инициалы

Место выполнения работы **ФГБОУ ВО «НИУ «МЭИ»**

СОДЕРЖАНИЕ РАЗДЕЛОВ ЗАДАНИЯ И ИСХОДНЫЕ ДАННЫЕ

Введение. Постановка задачи.

Глава 1. Обзор существующих методов анализа электрофизиологических исследований. Обзор существующих методов машинного обучения.

Выбор метода машинного обучения для проведения экспериментов.

Определение требований к выбору баз данных. Выбор наборов данных.

Глава 2. Описание выбранных наборов. Сравнение наборов данных.

Предобработка данных. Подготовка наборов данных для интеллектуального анализа.

Глава 3. Описание выбранного метода. Выбор метрик оценки качества. Проведение компьютерных экспериментов с использованием интеллектуального анализа данных.

Заключение. Основные результаты работы.

ПЕРЕЧЕНЬ ГРАФИЧЕСКОГО МАТЕРИАЛА

Количество листов	0
-------------------	---

Количество слайдов в презентации	18
----------------------------------	----

РЕКОМЕНДУЕМАЯ ЛИТЕРАТУРА

1. Элбон, К. Машинное обучение и анализ данных с использованием Python. Санкт-Петербург: БВХ-Петербург, 2019.

2. MachineLearning.ru: профессиональный информационно-аналитический ресурс, посвященный машинному обучению, распознаванию образов и интеллектуальному анализу данных [Электронный ресурс], URL: <http://www.machinelearning.ru>.

3. eLIBRARY.RU: научная электронная библиотека [Электронный ресурс], URL: <https://elibrary.ru>, Режим доступа: для зарегистрированных пользователей.

4. Жерон, О. Прикладное машинное обучение с помощью Scikit-Learn и TensorFlow, Санкт-Петербург: ООО “Альфа-книга”, 2018.

5. Николенко С., Кадуринов А., Архангельская Е. Глубокое обучение. Погружение в мир нейронных сетей, Санкт-Петербург: Питер, 2018.

6. Aleksandr P. Ereemeev, Irina V. Tsapenko. THE USE OF COGNITIVE GRAPHICS IN THE DIAGNOSIS OF COMPLEX VISION PATHOLOGIES. // International Journal “Information Theories and Applications”, Vol. 26, Number 1, 2019. Pp. 83-99.

7. Еремеев А.П., Ивлиев С.А. Методы и программные средства для анализа и диагностики сложных патологий зрения. // Вестник МЭИ. 2020. № 5. – С. 140-147.

Аннотация

В данной работе исследуются методы интеллектуального анализа данных электрофизиологических исследований на примере результатов электрокардиографии. Проводятся эксперименты с применением реализованного метода машинного обучения и двух баз данных. Выбор баз данных происходит по описанным в работе критериям, отвечающим параметрам и характеристикам медицинских приборов (электрокардиографов). В представленной работе подробно рассматривается неотъемлемая часть методов интеллектуального анализа – предобработка, целью которой является подготовка данных из разных источников для последующего машинного обучения на основе искусственных нейронных сетей. В целом структура работы – ряд последовательных, подробно описанных этапов взаимодействия с данными и методами машинного обучения. Результаты проведенных экспериментов, позволили сделать заключения о необходимости каждого этапа предобработки и возможности совместного использования разных баз данных.

Annotation

In this paper, the methods of intellectual analysis of electrophysiological research data are studied on the example of the results of electrocardiography. Experiments are being conducted using the implemented machine learning method and two databases. The selection of databases takes place according to the criteria described in the work that meet the parameters and characteristics of medical devices (electrocardiographs). In the presented work, an integral part of the methods of intellectual analysis is considered in detail – pre-processing, the purpose of which is to prepare data from various sources for subsequent machine learning based on artificial neural networks. In general, the structure of the work is a series of sequential, detailed stages of interaction with data and machine learning methods. The results of the experiments made it possible to draw conclusions about the need for each stage of preprocessing and the possibility of sharing different databases.

Содержание

СПИСОК ОСНОВНЫХ СОКРАЩЕНИЙ	6
ПОСТАНОВКА ЗАДАЧИ	7
1. ОБЗОР ПРЕДМЕТНОЙ ОБЛАСТИ И СУЩЕСТВУЮЩИХ МАТЕРИАЛОВ	11
1.1. Определение основных понятий	11
1.2. Распространённые алгоритмы моделей машинного обучения	18
1.3. Методы анализа электрофизиологических исследований	20
1.4. Выбор метода машинного обучения.....	20
1.5. Выбор набора данных для обучающего и тестового множеств.....	21
1.6. Выбор набора данных для валидации	21
1.7. Выводы к главе 1	22
2. ПОДГОТОВКА ДАННЫХ.....	23
2.1. Описание набора данных PTB-XL	23
2.2. Описание набора данных LUDB	24
2.3. Совмещение маркировок наборов	28
2.4. Порядок подготовки наборов	33
2.5. Выводы к главе 2	39
3. ПРОВЕДЕНИЕ ЭКСПЕРИМЕНТОВ И АНАЛИЗ РЕЗУЛЬТАТОВ.....	40
3.1. Описание выбранной модели	40
3.2. Выбор метрик оценки качества.....	42
3.3. Результаты проведения экспериментов.....	42
3.5. Вывод к главе 3	46
ЗАКЛЮЧЕНИЕ	47
Список используемых источников.....	48
Приложения	51
Приложение 1. Результаты экспериментов.....	51

СПИСОК ОСНОВНЫХ СОКРАЩЕНИЙ

CNN – convolutional neural network (свёрточная нейронная сеть);

kNN – k-nearest neighbors algorithm (метод k-ближайших соседей);

SVM – support vector machine (метода опорных векторов);

БД – база данных;

ИАД – интеллектуальный анализ данных;

ИИ – искусственный интеллект;

ИНС – искусственная нейронная сеть;

СИИ – система искусственного интеллекта (интеллектуальная система);

СНД – сопоставленные наборы данных;

ЭКГ – электрокардиограмма.

ПОСТАНОВКА ЗАДАЧИ

При диагностировании пациентов в медицине одним из стандартных обследований является снятие электрокардиограммы (ЭКГ). Данное обследование назначается при подозрении отклонений в работе сердца, для дифференциальной диагностики заболевания. Таких пациентов достаточно, чтобы дать серьезную нагрузку врачам функциональной диагностики и понизить качество расшифровки результатов.

Специалист при расшифровке проверяет наличие в графических данных отклонений от нормы и по типу выявленных отклонений делает определённое заключение.

Нерасшифрованными результатами одного обследования являются несколько отрезков временных рядов, которые возможно классифицировать с точностью, не уступающей точности экспертной оценки, в автоматическом режиме с помощью интеллектуальных систем (системы искусственного интеллекта, СИИ), осуществляющих интеллектуальный анализ данных. Главная задача – выбор или разработка СИИ, подходящей к конкретным данным.

Существуют способы автоматического подбора метода машинного обучения для той или иной выборки данных. Однако, не теряет своей актуальности и ручной анализ, который позволяет понять закономерности в данных и, следовательно, провести более точный выбор методов и настройку параметров моделей машинного обучения.

Попытки создания систем (в том числе с применением методов искусственного интеллекта), способных находить патологии сердца по отведениям электрокардиограммы есть, но тренировка и тестирование модели, как правило, проводятся на наборах данных уже существующей базы или поступающих из одного источника (одного медицинского центра, института, собирающего подобные сведения и т.п.).

Актуальность

При изучении существующих материалов этой предметной области встречались работы, в которых обучение и тестирование моделей производились на одном наборе данных, путём его разделения. Например, в [1–3] именно так используется база данных (БД) MIT-BIH Arrhythmia [4]. Надо отметить, что MIT-BIH Arrhythmia – достаточно старый набор данных, но аналогов по длительности записи до сих пор в открытом доступе нет. Ситуацию с подбором подходящей БД осложняют различные факторы:

- длительность сбора данных: если сбор данных будет осуществлять одна поликлиника с одним аппаратом ЭКГ и постоянным потоком пациентов, тогда в день при лучших обстоятельствах можно будет принять около 24 человек из расчёта 20 минут на человека, что в сумме даёт 720 человек в месяц. При таких обстоятельствах весьма посредственный набор данных в пару десятков тысяч результатов обследований будет собираться около двух лет;
- разное оборудование: в большинстве случаев аппараты для электрофизиологических обследований отличаются даже в стенах одного медицинского учреждения. Отличаются как форматом вывода результатов (аналоговые и цифровые), так и более тонкими моментами наподобие частоты оцифровки сигнала, скоростью записи и т.д.;
- разная маркировка (выявление патологий): невозможно возложить задачу по маркировке всех собираемых данных на одного человека, поэтому так или иначе в зависимости от опыта и внимательности эксперта маркировка может отличаться. Во многих случаях присутствует сразу несколько патологий, а иногда для их подтверждения одной электрокардиограммы недостаточно. Дополнительные мероприятия могут нелинейно замедлять время сбора данных;

- разная разметка (разделение сигнала на зубцы и другие фрагменты): процесс, требующий больших временных затрат при выполнении экспертом. В большинстве случаев от него отказываются или выполняют только в рамках текущих задач по мере необходимости;
- другие проблемы: электрофизиологическое обследование имеет большую свободу в своём процессе. Например, крепление электродов, соблюдение определённого режима пациентом, взаимодействие с оборудованием медицинских работников и т.д.

Группировку факторов можно проводить разными способами. Можно пытаться добавлять контроль за сбором данных, но основную проблему будут составлять те факторы, о которых известно меньше всего.

В представленной работе будет осуществлена попытка совмещения разных БД с помощью различных способов предобработки, а также использованы наиболее свежие из доступных обследований. Один набор будет выполнять функцию обучающего и тестового множеств для обучения искусственных нейронных сетей (ИНС). А другой будет выступать валидационным (контрольным) набором. Таким образом, ситуация будет приближена к реальной, с которой неизбежно столкнётся СИИ использующая при интеллектуальном анализе данных (ИАД) машинное обучение на основе ИНС.

Среди известных работ подобных результатов экспериментов найдено не было. Подготовленная в качестве валидационного набора база данных таким способом будет использована впервые.

Постановка задач и использованные методы

В процессе выполнения ВКР планируется решение следующих основных задач.

Оценка возможности совмещения нескольких наборов данных в один путём масштабирования, автоматической или ручной разметки и маркировки и т.д.

Определение требований, необходимых для совмещения, которые в дальнейшем позволят синтезировать искусственные данные или типизировать данные, поступающие из разных источников.

Будут использованы стандартные методы предобработки (препроцессинга данных): масштабирование или стандартизация, очистка от выбросов, устранение шума и понижение размерности. После чего подготовленные наборы данных будут использованы для машинного обучения ИНС и контроля качества этого обучения. Полученные результаты будут определять приоритетность тех или иных этапов предобработки данных для ИАД типа ЭКГ.

Основными методами исследования являются проведение компьютерных экспериментов, основанных на реализованном методе ИАД электрофизических исследований с применением машинного обучения, перебор комбинаций предобработки данных и анализ полученных результатов.

1. ОБЗОР ПРЕДМЕТНОЙ ОБЛАСТИ И СУЩЕСТВУЮЩИХ МАТЕРИАЛОВ

Для правильного понимания целей и действий, описанных в следующих главах, необходимо привести краткое описание медицинских терминов, технологий, используемых при ЭКГ обследовании, и непосредственно самих результатов.

1.1. Определение основных понятий

Электрокардиограмма (ЭКГ) – это кривая или, если формально, временной ряд с некоторой периодичностью во времени, отражающий изменение разности потенциалов двух разных точек тела, возникающих из-за электрических процессов, источником которых является работающее сердце человека [5].

Отведения и группы отведений

В самом простом случае один временной ряд, характеризующий работу проводящей системы организма, можно записать, как разность потенциалов между любыми двумя точками находящимися на разном удалении от сердца. По такому временному ряду уже можно судить о работе сердца. Например, можно сказать есть ли тахикардия или брадикардия в самом широком смысле. Но определить с достаточной точностью, чем вызвана или конкретизировать патологию уже нельзя. Поэтому с помощью экспериментов были определены способы размещения считывающих электродов, которые уже позволяют оценить работу сердца с большей точностью: определить место патологии, её природу и т.д.

В настоящее время распространённым вариантом кардиографа, является аппарат, записывающий разности потенциалов между двенадцатью парами точек в течении времени [6]. Формально набор измерений между одной парой точек называется отведением и результат измерений подобного прибора – 12 общепринятых отведений. Эти отведения в свою очередь делятся на группы по типу электродов их расположению. Рассмотрим их подробнее.

Отведения от конечностей (стандартные)

Стандартных отведений предложенных В. Эйнтховеном (рис. 1.1) [5] три и обозначаются они римскими цифрами I, II, III. За I стандартное отведение принято расположение регистрирующих электродов на правой и левой руках, за II – на правой руке и левой ноге, за III – на левой руке и левой ноге. Прямую, соединяющую точки расположения двух электродов противоположной полярности, называют осью данного отведения [7].




Рисунок 1.1. Стандартные отведения Эйнтховена

Усиленные отведения

Усиленные отведения получили своё название потому, что уровень исходного сигнала значительно ниже, чем в стандартных отведениях и для удобства расшифровки было принято решение его усиливать. Усиленных отведений также как и стандартных три. Электроды в свою очередь устанавливаются так:

- aVR – правая рука и объединенный электрод левой ноги и левой руки;
- aVL – левая рука и объединенный электрод с левой ноги и правой руки;
- aVF – левая нога и объединенный электрод с левой и правой рук.

Пример усиленных отведений Гольдбергера представлен на рис. 1.2 [8]. Усиленные отведения последовательно снимаются с каждой оси тре-угольника Эйнтховена.




Рисунок 1.2. Усиленные отведения Гольдбергера

Грудные отведения

Грудные отведения регистрируют изменения электродвижущей силы в горизонтальной плоскости в отличие от других, вышеописанных, отведений. Из всего разнообразия грудных отведений для первичной диагностики чаще всего используют грудные отведения Вильсона (рис. 1.3) [9]:

- V1 – четвертое межреберье у правого края грудины;
- V2 – четвертое межреберье у левого края грудины;
- V3 – посередине между электродами V1 и V2;
- V4 – пятое межреберье по левой среднеключичной линии;
- V5 – по высоте на уровне электрода V4 по левой передней подмышечной линии;
- V6 – по высоте на уровне электрода V4 по левой средней подмышечной линии.




Рисунок 1.3. Грудные отведения Вильсона

Стоит отметить, что в установке грудных отведений, изображённых на рисунке 1.3, чаще всего возникают затруднения, которые не дают из-за разного строения тела установить их одинаково у всех пациентов.

Рисунок 1.4 [10] иллюстрирует, что если сдвинуть электрод со своего места расположения, то через него будут проходить другие силовые линии, как следствие в соответствующем отведении изменится уровень сигнала. А это как раз и является одной из причин отличия результатов обследований.




Рисунок 1.4. Схематичное изображение электрического поля сердца по схеме Уоллера

На рисунке 1.5 [11] изображены общепринятые 12 отведений, работая с которыми врач функциональной диагностики выявляет патологии и ставит соответствующий им диагноз. По этому примеру явно просматривается разный уровень сигналов. Учитывая, что на рисунке 1.5 приведён эскиз ЭКГ здорового человека, можно ожидать большего отличия, в результатах обследования человека, имеющего патологические изменения.




Рисунок 1.5. Отличия отведений друг от друга

Составляющие одного отведения

В норме одно отведение (рис. 1.6) [12] состоит из зубцов разной формы и отрезков изолинии. Зубцы, направленные вверх, называются положительными, вниз – отрицательными. В нормальных условиях зубцы бывают 5 видов:

P – невысокий, закругленный, в некоторых случаях видно ямку посередине;

Q – небольшой острый;

R – большой и острый;

S – острый, относительно небольшой;

T – закругленный, схожий с зубцом P.

На рисунке 1.6 присутствует **волна U**. Она соответствует процессу реполяризации предсердий. В большинстве случаев на результатах обследования эта волна сливается с шумом и слабо различима. В условиях представленной работы факт её наличия не учитывается.




Рисунок 1.6. Схема нормальной ЭКГ человека

Зубец Р фиксируется в начале сердечного сокращения при возбуждении предсердий, вызванном работой синусового узла. Сначала возбуждается левое предсердие, а затем – правое. Поскольку это процесс происходит волнообразно, постепенно захватывая мышцы этой области сердца, образующийся зубец похож на волну. Различные патологии предсердий обязательно сказываются на состоянии этого участка кардиограммы.

Зубец Т при нарушениях может сглаживаться, увеличиваться, приобретать треугольную форму или даже переворачиваться относительно средней линии кардиограммы.

Затем возбуждение переходит к атриовентрикулярному узлу, расположенному в середине сердца. Отличительная черта этой области – способность задерживать проходящий сигнал. Из-за резкого снижения скорости прохождения импульса на кардиограмме в этот период появляется ровный участок, следующий за зубцом Р.

Отклонение от прямой линии в этой зоне указывает на нарушение прохождения импульса по атриовентрикулярному узлу (АВ-узлу).

Зубец Q. Затем начинается возбуждение желудочков. Нервный импульс от АВ-узла проходит вниз к пучку Гиса и переходит на его ножки. Такой период отмечается на кардиограмме небольшим отрицательным зубцом Q.

Зубцы R и S. В дальнейшем импульс доходит до нижнего полюса сердца, и происходит сокращение желудочков, при котором кровь из них выбрасывается в предсердия. Поскольку сердечной мышце приходится выталкивать достаточно большой объем крови, такой процесс сопровождается выраженным электрическим импульсом, и на ЭКГ появляется резко выраженный острый зубец R. Затем возбуждаются кончики ножек пучка Гиса, что вызывает образование небольшого зубца S.

Особенности сегмента ST. После полной фазы сокращения сердцу нужно успокоиться. Однако возбуждение проходит не сразу, задерживаясь на какое-то время в проводящей системе миокарда. В этот момент в сердечных мышцах наблюдается сразу два процесса – возбуждения и торможения, которые уравновешивают друг друга. Так появляется плоский сегмент ST.

При некоторых заболеваниях сердца он может удлиняться и приобретать волнообразную форму.

Зубец T. В конце сердечного сокращения происходит восстановление желудочков. Это процесс называется реполяризацией – на кардиограмме ему соответствует волнообразный зубец T.

При расшифровке ЭКГ специалист измеряет высоту (вольтаж) зубцов, а также их продолжительность в секундах. Измеряются и показатели наиболее важных интервалов. Обязательно делается акцент на изменённых зубцах. Затем эти данные используются для расшифровки ЭКГ с целью обнаружения кардиопатологий.

1.2. Распространённые алгоритмы моделей машинного обучения

В этой работе требуется определять патологии, т. е. решать задачу классификации, относя каждое обследование к одному из классов диагнозов. Поэтому дальше при обзоре методов машинного обучения, в качестве решаемой задачи будет подразумеваться задача классификации, для решения которой будут использованы следующие методы.

1. *Дерево принятия решений* – средство поддержки принятия решения со структурой дерева. В его рёбрах находятся признаки, от которых зависит значение целевой функции, а в листьях этого дерева находятся значения целевой функции [13].

Достоинства этого метода заключаются в том, что он не требует подготовки данных, работает с интервальными признаками, позволяет логически интерпретировать процесс вычисления значения целевой функции, быстро обрабатывает большой объём входных данных.

Недостатками этого метода будет то, что задача получения оптимального метода решения является NP-полной, дерево может получиться неоправданно глубоким и не способно легко переобучиться (перестроиться).

2. *Байесовский классификатор* – широкий класс алгоритмов классификации, основанный на принципе максимума апостериорной вероятности. Для классифицируемого объекта вычисляются функции правдоподобия каждого из классов, по ним вычисляются апостериорные вероятности классов. Объект относится к тому классу, для которого апостериорная вероятность максимальна [14].

Достоинствами метода будет простота, а главным недостатком станет требовательность к независимости признаков.

3. Метод опорных векторов (SVM) – линейный алгоритм, который основан на разделении классов гиперплоскостью [15]. Алгоритм подбирает такое расположение плоскости, чтобы зазор между представителями разных классов был максимален. Гиперплоскостью здесь называется $(n - 1)$ -мерная плоскость в n -мерном Евклидовом пространстве, разделяющая всё n -мерное пространства на две части.

Достоинствами SVM являются быстрота нахождения решающей функции и наличие единственного решения, поскольку метод сводится к задаче квадратичного программирования в выпуклой области.

Недостатком метода является его чувствительность к шуму и выбросам в исходных данных, а также к их стандартизации. Проблему будет составлять и отсутствие общего подхода к автоматическому выбору ядра в случае линейной неразделимости классов.

4. Свёрточная нейронная сеть (CNN) – специальная архитектура искусственных нейронных сетей, которая моделирует некоторые особенности зрительной коры головного мозга человека [16].

Основная идея этой архитектуры состоит в том, что обработка отдельного участка вектора или матрицы признаков должна происходить независимо от его расположения.

Достоинства использования CNN применительно к классификации электрокардиограмм заключается в том, что сигнал периодичный, и ключевое значение в большинстве случаев имеют его фрагменты.

Недостатком этого подхода является длительность получения решающей функции в сравнении с методами, описанными выше.

5. Метод k -ближайших соседей (kNN) – самый простой алгоритм классификации, который относит объект к тому или иному классу в зависимости от того к какому классу относится большинство его соседей [17].

Недостатками этого метода являются требовательность к чистоте данных, выбор метрики и количества соседей, а также серьезное замедление при увеличении размера выборки.

1.3. Методы анализа электрофизиологических исследований

Проведённый анализ показал, что чаще всего для ИАД ЭКГ используют методы kNN, SVM и CNN.

Например, для определения границ волн в статье [18] автор использует метод kNN. Этот же метод используется и авторами в статьях [19-22] уже для классификации обследований по патологиям.

В работах [23-25] чаще всего используется метод SVM, в том числе как вспомогательный метод для подбора параметров других моделей.

Следует отметить, что подавляющее большинство работ последних лет использует CNN как основной алгоритм машинного обучения для обработки в контексте ИАД результатов электрофизиологических исследований. Работы в большинстве случаев представляют обзор одной или нескольких архитектур ИНС; обучения и тестирования моделей на наборах из одной БД; сравнения полученных значений метрик качества с метриками из схожих исследований, опубликованных ранее (см., например, работы [26-32]).

1.4. Выбор метода машинного обучения

В представленной работе будет использован наиболее распространённый способ анализа электрофизиологических обследований, а именно одна из архитектур ИНС типа CNN. Выбор обосновывается, расширением инструментов предобработки данных, а также относительной простотой реализации необходимой архитектуры, связанной с наличием большого количества описаний уже проведённых исследований. Это позволит сконцентрироваться на изучении наборов данных и их типизации.

1.5. Выбор набора данных для обучающего и тестового множеств

Главный критерий, по которому будут подбираться наборы, это совпадение типа данных и типа маркировок. С установлением такого критерия круг поиска уже достаточно сильно сужается, поскольку в большинстве случаев данные собираются под какую-то конкретную задачу, а значит полное аннотирование не производится ввиду нецелесообразности. Выбор типа данных осуществляется с учётом распространённости исходных, непосредственно сразу после обследования, данных. В нашем случае это 12 отведений. Каждое отведение длительностью 10 секунд. Тип маркировок определяется после составления пар обучающая-валидационная выборки по критерию, выбранному выше.

При выборе множества для обучения и теста предпочтение отдаётся наибольшему из подходящих. Остальные критерии выбираются уже по ходу сравнения наборов данных.

Итогом сравнения наборов был выбор в пользу базы данных PTB-XL [33].

1.6. Выбор набора данных для валидации

Помимо совпадения маркировок и технических параметров с набором, набором, выбранным выше, для контрольного набора главным требованием была максимальная приближенность к обследованиям, которые встречаются в медицинских учреждениях. А значит описание патологий в этих данных должно быть как можно подробнее, т.е. каждое обследование должно иметь полный патологический список, поскольку патологии встречаются поодиночке редко. Ну и в силу того, что для валидации большой объём не требуется, в поле зрения оказались наборы, ранее таким образом не используемые.

Выбор остановился на наборе, собранном Нижегородским государственным университет имени Н.И. Лобачевского LUDB [34].

1.7. Выводы к главе 1

Изучены материалы предметной области, а именно принципы проведения ЭКГ обследования, значения составляющих одного результата обследования и типы съёмочного оборудования.

Отмечены моменты, на которых возможны внесения ошибок и искажений в результаты ЭКГ.

Проведён обзор существующих работ по теме ИАД, рассмотрены популярные модели ИАД, и выбран на основе анализа подходящий метод машинного обучения.

Дан обзор имеющихся БД электрофизиологических исследований типа ЭКГ в открытом доступе. Определены критерии выбора БД и произведён подбор обучающего и валидационного множеств.

2. ПОДГОТОВКА ДАННЫХ

2.1. Описание набора данных РТВ-XL

Используемый в работе набор данных (БД) РТВ-XL опубликован в 2020 году [33]. Имеет двойную маркировку на классы и подклассы патологий. Объем этого набора составляет 21837 обследований, полученных с 18885 пациентов. В идеальном случае такого объема данных вполне достаточно для тренировки ИНС при машинном обучении.

Метки БД РТВ-XL представляют из себя аббревиатуры диагнозов и имеют двухуровневую иерархическую структуру типа «класс-подкласс».

На рисунке 2.1 [35] приведена диаграмма, описывающая общий состав данных, для оценки содержимого. Малое кольцо на диаграмме разделено на *классы* диагнозов и класс обследований, на которых патологий не обнаружено. Большое кольцо разделено в соответствии с классами на *подклассы* диагнозов.




Рисунок 2.1. Общий состав данных

Далее, на рисунке 2.2 [36] указан количественный состав каждого класса, который будет учтен при отборе классов и подклассов в БД РТВ-XL.




Рисунок 2.2. Соотношение классов и подклассов патологий

При непосредственной работе с БД РТВ-XL был обнаружен третий, самый низкий уровень иерархической структуры, неупомянутый в описании и названный создателями БД как *индекс*.

2.2. Описание набора данных LUDB

Набор данных (БД) LUDB представляет из себя обследования, собранные в 2017-2018 годах в городской больнице Нижнего Новгорода [34]. Все диагнозы собраны у людей с заболеваниями, поэтому обследований, не содержащих отклонений, нет.

Маркировка в этой БД представлена упорядоченными по степени присутствия списками развёрнутых названий патологий и диагнозов для каждого обследования. Отсутствие данных с одной и менее патологией подтверждает предположение о редкости пациентов с абсолютно здоровым или имеющем только одно отклонение от нормы сердцем.

Несмотря на то, что при выборе наборов на совпадение маркировок обращалось особое внимание, получить полного совпадения не удалось. Требуется дополнительное сопоставление меток диагностических классов и подклассов. Поскольку в описании данных информации для выполнения подобной работы недостаточно, её придётся выполнять при непосредственном переборе данных каждого набора.

Произведём обзор и сравнение содержимого двух выбранных БД, исходя из их описания. Стоит отметить, что диаграммы, отображающие количественный состав классов БД LUBD, были созданы на основе сопроводительного описания этой БД.

Из диаграммы, представленной на рисунке 2.3, следует, что в контрольном наборе есть информация, которая интереса не представляет. Тип ритма (rhythms), наклон электрической оси сердца (electric axis of the heart), наличие экстрасистол (extrasystolies), тип сердцебиения (cardiac pacing) и неспецифические аномалии реполяризации (non-specific repolarization abnormalities) использовать не получится, поскольку в обучающем наборе такие маркировки отсутствуют.




Рисунок 2.3. Распределение диагностических классов

Состав каждого класса также придется проверить и сравнить. По диаграммам видно, что количественное наполнение классов подклассами разное. Также придётся учитывать, что хорошая подстройка модели на базе ИНС CNN произойдёт только под те классы, которые представлены в достаточном количестве в обучающем множестве. Достаточным количеством представителей каждого класса будем считать такое, которое отличается от количества любого другого класса не более, чем вдвое. В противном случае будем считать, что имеет место сильный дисбаланс классов и можно ожидать плохого качества на контрольной выборке для мало представленных классов в обучающем множестве.

По диаграмме рисунка 2.2 ясно, что самой распространённой патологией среди нарушений проводимости (CD) в наборе данных PTB-XL, является фасцикулярная блокада (LAFB/LPFB). В контрольном наборе данных LUDB (рис. 2.4) такая патология отсутствует, поэтому в обучении модели её использовать нецелесообразно. Также приходится поступить и с Синдромом Вольфа-Паркинсона-Уайта (WPW).




Рисунок 2.4. Распределение нарушений проводимости

Стоит отметить проблему подобных несоответствий, поскольку даже в пределах большего, чем два, количества наборов данных сложно сформировать необходимые множества для обучения и контроля, покрывающие все классы патологий сердца. В частности, такое положение вызвано различием технических параметров (количество отведений, частота оцифровки сигнала, маркировка, длительность, и т.д.).

По результату сравнения диаграмм распределения типов гипертрофий сердца (рис. 2.2, а также 2.5), становятся понятны подклассы, от которых можно избавиться в виду их малочисленности или отсутствия в обучающем множестве. Такими в данном случае являются гипертрофии правой стороны сердца (right atrial hypertrophy, right ventricular hypertrophy в БД LUDB и RVH в БД PTB-XL) и межжелудочковой перегородки (SEHYP в БД PTB-XL), а также перегрузки правого предсердия (RAO/RAE в БД PTB-XL и right atrial overload) и левого желудочка (left ventricular overload в БД LUDB).




Рисунок 2.5. Распределение типов гипертрофии

Диаграмма (рис. 2.6) показывает, что в классе Ischemia БД LUDB представлено сразу 2 класса БД PTB-XL. Причём значительно подробнее. Следовательно, необходимо провести работу по распределению класса Ischemia по классам MI и STTC.




Рисунок 2.6. Распределение типов ишемии.

2.3. Совмещение маркировок наборов

В этом подразделе приведена таблица 2.1, составленная на основе подробного анализа содержимого двух БД (РТВ-XL и LUBD), дословного перевода и изучения терминов в медицинской литературе.

В таблице представлены трех уровневое разбиение по классам, подклассам и индексам БД РТВ-XL и поставленные в соответствие одноуровневые диагнозы БД LUBD.

Разделение на классы останется таким же как в обучающем наборе (БД РТВ-XL), а наполненность подклассами будет меняться в зависимости от подготовленных для обучения ИНС сопоставленных наборов данных (СНД).

Таблица 2.1

Результат сопоставления диагнозов						
Метка класса PTB-XL	Расшифровка метки класса PTB-XL	Метка под-класса PTB-XL	Индекс патологии	Расшифровка метки подкласса PTB-XL	Метка LUDB	Перевод метки подкласса PTB-XL
NORM	Normal ECG	NORM	NORM	Normal ECG	—	ЭКГ в норме
MI	Myocardial infarction (Инфаркт миокарда)	IMI	IMI	Inferior MI	STEMI: inferior wall	Нижний ИМ
			ILMI	Inferolateral MI		Нижнебоковой ИМ
			IPLMI	Inferoposterolateral MI		Нижне-задне-боковой ИМ
			IPMI	Inferoposterior MI		Нижне-заний ИМ
			INJIN	Subendocardial injury in inferior leads		Субэндокардиальная травма в нижних отведениях
			INJIL	Subendocardial injury in inferolateral leads		Субэндокардиальная травма в нижнелатеральных отведениях
		AMI	AMI	Anterior MI	STEMI: anterior wall	Передний ИМ
			ALMI	Anterolateral MI		Переднебоковой ИМ
			ASMI	Anteroseptal MI		Переднеперегородочный ИМ
			INJAS	Subendocardial injury in anteroseptal leads		Субэндокардиальная травма в переднесептальных отведениях
			INJLA	Subendocardial injury in lateral leads		Субэндокардиальная травма в боковых отведениях
			INJAL	Subendocardial injury in anterolateral leads		Субэндокардиальная травма в переднебоковых отведениях
		LMI	LMI	Lateral MI	STEMI: lateral wall	Боковой ИМ
		PMI	PMI	Posterior MI	—	Задний ИМ
HYP		LAO/LAE	LAO/LAE	Left atrial overload/enlargement	Left atrial overload	Перегрузка/увеличение левого предсердия
					Left atrial hypertrophy	

	Hypertrophy (Гипертрофия)	LVH	LVH	Left ventricular hypertrophy	Left ventricular hypertrophy	Гипертрофия левого желудочка
		RAO/RAE	RAO/RAE	Right atrial overload/enlargement	Right atrial overload	Перегрузка/увеличение правого предсердия
					Right atrial hypertrophy	
		RVH	RVH	Right ventricular hypertrophy	Right ventricular hypertrophy	Гипертрофия правого желудочка
		SEHYP	SEHYP	Septal hypertrophy	—	Гипертрофия желудочковой перегородки
CD	Conduction disorder (Нарушение проводимости)	CLBBB	CLBBB	Complete left bundle branch block	Complete left bundle branch block	Полная блокада левой ножки пучка Гиса
		CRBBB	CRBBB	Complete right bundle branch block	Complete right bundle branch block	Полная блокада правой ножки пучка Гиса
		ILBBB	ILBBB	Incomplete left bundle branch block	Incomplete left bundle branch block	Неполная блокада левой ножки пучка Гиса
		IRBBB	IRBBB	Incomplete right bundle branch block	Incomplete right bundle branch block	Неполная блокада правой ножки пучка Гиса
		IVCD	IVCD	Non-specific intraventricular conduction disturbances	Non-specific intraventricular conduction delay	Неспецифические нарушения внутрижелудочковой проводимости
		LAFB/LPFB	LAFB	Left anterior fascicular block	—	Левая передняя фасцикулярная блокада
			LPFB	Left posterior fascicular block		Левая задняя фасцикулярная блокада
		WPW	WPW	Wolf-Parkinson-White syndrome	—	Синдром Вольфа-Паркинсона-Уайта
		_AVB	1AVB	First degree AV block	I degree AV block	AB-блокада первой степени
			2AVB	Second degree AV block	—	AB-блокада второй степени

			3AVB	Third degree AV block	III degree AV-block	АВ-блокада третьей степени
STTC	ST/T-Change	ISCA	ISCAL	Ischemic in anterolateral leads	—	Ишемия в переднебоковых отведениях
			ISCAS	Ischemic in antero-septal leads	—	Ишемия в переднеперебоковых отведениях
			ISCLA	Ischemic in lateral leads	Ischemia: lateral wall	Ишемия в боковых отведениях
			ISCAN	Ischemic in anterior leads	Ischemia: anterior wall	Ишемия в передних отведениях
		ISCI	ISCIN	Ischemic in inferior leads	Ischemia: inferior wall	Ишемия в нижних отведениях
			ISCIL	Ischemic in inferolateral leads	—	Ишемия в нижнебоковых отведениях
		ISC_	ISC_	Non-specific ischemic	—	Неспецифическая ишемия
		NST_	NST_	Non-specific ST changes	—	Неспецифические изменения ST
		STTC	NDT	Non-diagnostic T abnormalities	—	Недиагностические Т-аномалии
			DIG	Digitalis-effect		Дигиталис-эффект
			LNGQT	Long QT-interval		Длинный QT-интервал
			ANEUR	ST-T changes compatible with ventricular aneurysm		Изменения ST-T, совместимые с аневризмой желудочков
			EL	Electrolytic disturbance or drug		Электролитическое или лекарственное нарушение

Сформированные наборы классов

В результате сопоставления меток двух БД и оценки количества представителей каждого класса, подкласса и индекса в БД РТВ-XL были подготовлены СНД. Изменение составов при переходе от одних СНД к другим оформлено в виде таблицы 2.2. В представленной таблице также приведён объём получившихся классов в СНД до очистки от выбросов.

Таблица 2.2

Состав классов											
	СНД 1			СНД 2				СНД 3			
Класс	Подкласс	Индекс	Количество	Класс	Подкласс	Индекс	Количество	Класс	Подкласс	Индекс	Количество
МІ (2548)	ІМІ	ІМІ	831	МІ (1086)	ІМІ	ІМІ	995	МІ (1017)	ІМІ	ІМІ	1017
		ІІМІ	226								
		ІРІМІ	25								
		ІРМІ	24								
		ІНJIN	2								
		ІНJIL	4								
	АМІ	АМІ	88		АМІ	АМІ	91				
		АІМІ	89								
		АSМІ	1075								
		ІНJAS	120								
		ІНJLA	2								
		ІНJAL	38								
	LMI	LMI	21								
CD (2548)	CLBB B	CLBB B	468	CD (2351)	CLBB B	CLBB B	476	CD (2406)	CLBB B	CLBB B	492
	CRBB B	CRBB B	368		CRBB B	CRBB B	452		CRBB B	CRBB B	459
	ILBBB	ILBBB	42		IRBBB	IRBBB	990		IRBBB	IRBBB	995
	IRBBB	IRBBB	927		_AVB	1AVB	433		_AVB	1AVB	460
	IVCD	IVCD	446								
	_AVB	1AVB	292								
		3AVB	5								
HYP (922)	LAO/L AE	LAO/L AE	89	HYP (1065)	LAO/L AE	LAO/L AE	134	HYP (948)	LVH	LVH	948
	LVH	LVH	780		LVH	LVH	931				
	RAO/R AE	RAO/ RAE	47								
	RVH	RVH	6								

2.4. Порядок подготовки наборов

Осуществим подготовку каждого СНД для обучения, тестирования и валидации. Подготовка будет заключаться в:

- очистке СНД от выбросов;
- понижении исходной размерности;
- масштабировании;
- получении вейвлет-спектра;
- разделении набора данных РТВ-XL на обучение и тест.

Все манипуляции с данными, создание и тестирование моделей ИНС будут выполняться с помощью инструментов, предоставленных фреймворками языка Python 3.

Очистка от выбросов

Очистка от выбросов важный этап в предобработке данных. Большие значения, не имеющие смыслового значения, затрудняют обучение ИНС. Кажется, что в данных, собираемыми медицинскими работниками не может быть случайных значений. На практике же оказывается, что скачки значений могут происходить при отрыве электрода, при преждевременном завершении обследования, при различных внешних электромагнитных помехах и т.д. В случае выявления таких скачков на этапе просмотра медицинским работником, повторное обследование проводится только, когда искажение сигнала мешает постановке диагноза специалистом.

На рисунке 2.7 приведён из БД РТВ-XL пример скачка, расположенного в конце и присутствующего во всех отведениях. Маловероятно, что такой скачок связан с патологией сердца, скорее всего он произошёл в момент завершения обследования.




Рисунок 2.7. Пример выброса в конце сигнала

Под очисткой от выбросов будет подразумеваться процесс поиска таких аномалий и избавления от них.

Поскольку скачки в конце и начале обследований часто встречающаяся проблема, принято решение обрезать каждый сигнал на $\frac{1}{4}$ секунды с краёв. Такой подход позволяет избавиться от выброса и сохранить результат обследования в СНД.

Очистка от подобных скачков по середине сигнала будет осуществляться с помощью поиска и выбрасывания обследования целиком. Критерием наличия скачка будет выход отклонений за три стандартных для каждого отведения одного обследования.

Понижение размерности

Понижение размерности выполняется с целью ускорения процесса обучения ИНС, а также с целью избавления от незначительных колебаний сигнала. Для понижения размерности используется дискретное вейвлет преобразование. В качестве вейвлет-функции будем использовать вейвлет Добеши четвёртого прядка, хорошо показавший себя при ликвидации шума [37].

Масштабирование

Одним из главных требований к данным для использования их при обучении ИНС является нормализация данных. Значения даже разных отведений нормального ЭКГ обследования (рис. 1.5) находятся в достаточно узком диапазоне, но когда речь идёт об аномальном результате (патологии), то значения могут сильно выходить за пределы этого диапазона.

На рисунке 2.8 из БД LUBD приведён пример изменения силы сигнала одного обследования в пятом грудном и усиленном от правой руки отведениях при гипертрофии левого желудочка. В иных случаях, в частности при экстрасистолии, уровни сигнала могут отличаться в десятки раз.




Рисунок 2.8. Пример разницы амплитуд в двух отведениях одного обследования

В этой работе использованы:

- стандартизация данных на основе среднего значения и стандартного отклонения вычисляемых для каждого отведения каждого обследования отдельно;

$$x' = \frac{x - \mu}{\sigma}$$

- масштабирование на отрезок $[0,1]$, по минимальным и максимальным значениям каждого отведения каждого обследования.

$$x' = \frac{x - m}{M - m}$$

На рисунке 2.9 приведён пример стандартизации отведения одного обследования из БД РТВ-XL. Стандартизация сохраняет пропорции сигнала, но при этом получаемый диапазон значений сильно зависит от ряда в целом.

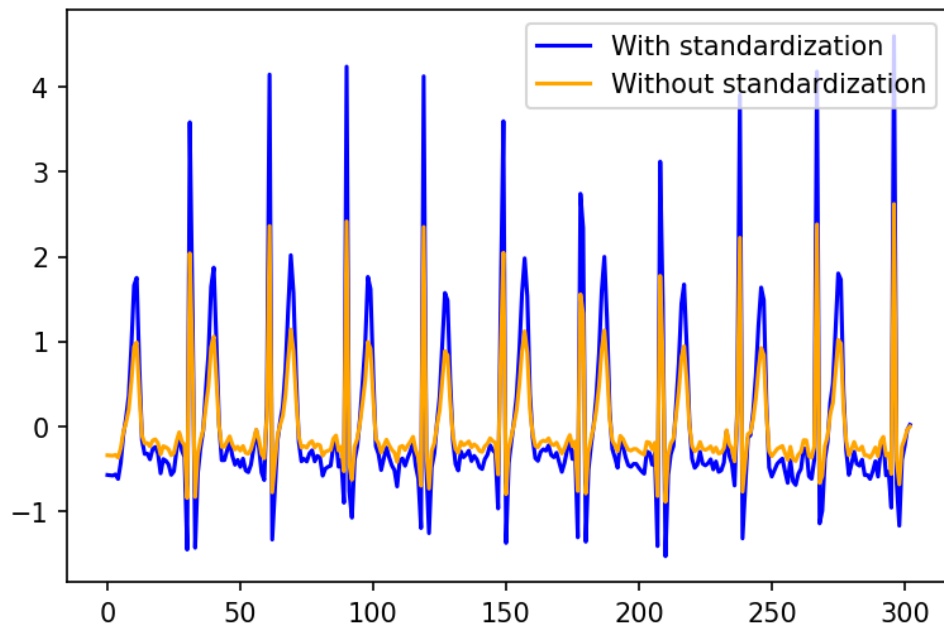


Рисунок 2.9. Результат проведения стандартизации

На рисунке 2.10 приведён пример масштабирования того же, что и в случае стандартизации, отведения. Пропорции сигнала изменены, но значения теперь находятся на отрезке от нуля до единицы.




Рисунок 2.10. Результат проведения масштабирования

Получение вейвлет-спектра

Получение вейвлет-спектра – это некий процесс позволяющий превратить временной ряд в изображение. Формально же это – свёртка последовательности входных данных с набором функций, генерируемых материнским вейвлетом.

С помощью этого преобразования низкие частоты имеют более детальное представление относительно времени, а высокие — относительно частоты [38]. Таким образом, мы раскрываем детали сигнала и переводим его в двумерный, привычный формат данных для свёрточной нейронной сети, что позволяет в дальнейшем при построении архитектуры модели использовать уже обученные на других изображениях фрагменты сети.

В качестве базисной функции будем использовать вейвлет, имеющий название «Мексиканская шляпа» и параметры, описанные в работе [39].

На рисунке 2.11 приведён двадцатиуровневый спектр, полученный в результате преобразования одного обследования БД РТВ-XL. Перед этим все отведения были укорочены на $1/4$ секунды с обеих сторон, затем выполнены масштабирование с использованием дискретного вейвлет-преобразования и трансформация двенадцати отведений в один вектор.




Рисунок 2.11. Результат получения вейвлет-спектра одного обследования

Разделение на обучение и тест

Разделение набора данных РТВ-XL осуществляется в конце в стандартном отношении 7 к 3, после проведения ряда описанных выше этапов предобработки и случайного перемешивания. Семь частей – обучающая выборка и три части – тестовая. Такое соотношение может быть использовано, поскольку в итоговых наборах после этапа очистки от выбросов не возникает сильного дисбаланса классов и представителей каждого класса достаточно для создания сбалансированного набора для обучения ИНС.

Полученные наборы

Для проведения дальнейших экспериментов, с обучением моделей, подготовим наборы данных путём включения и исключения этапов предобработки. Для удобства восприятия материалов исследования, в работе используется последовательность: отбор диагнозов, предобработка данных и подготовка наборов, обучение моделей и оценка результатов. В действительности состав данных, порядок предобработки и некоторые другие моменты были определены экспериментально.

На рисунке 2.12 представлена последовательность предобработки данных. Каждый путь диаграммы связан с отдельным набором «обучение-тест-валидация», для которого будет проведён эксперимент.

Финальные наборы данных формировались в процессе предобработки и фильтрации от экстремальных значений. Последний СНД 3 был сформирован после итоговой очистки от выбросов, когда стал известен состав каждого из них и определена целесообразность наличия малочисленных подклассов.

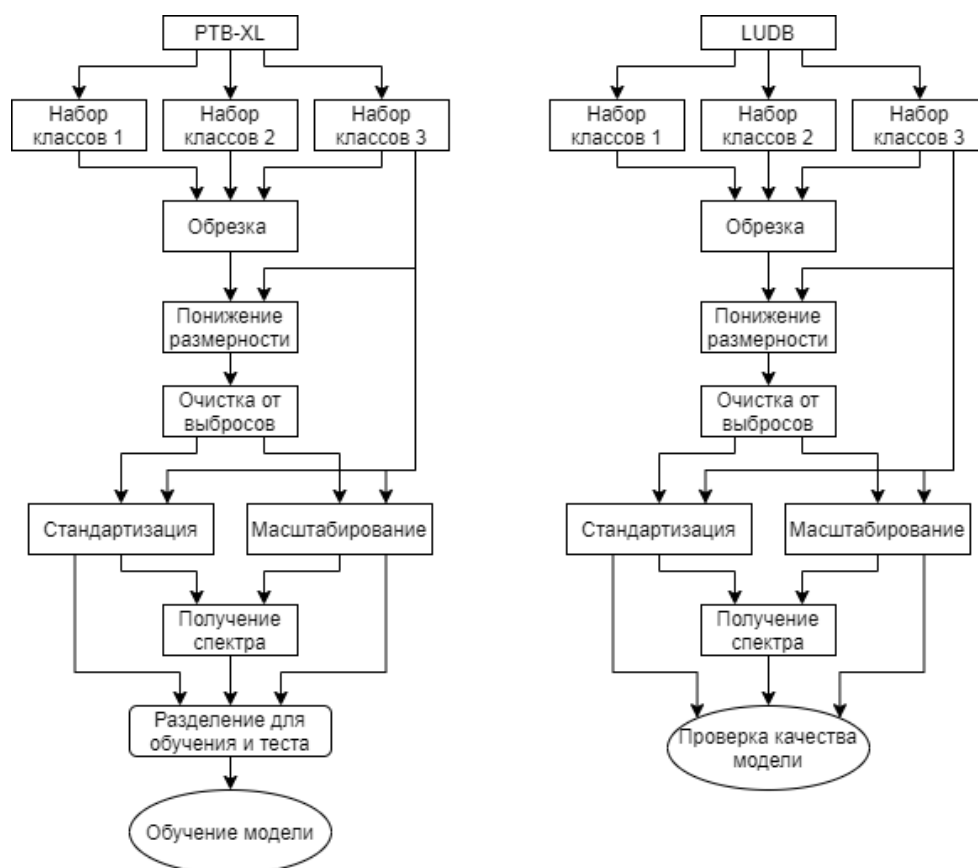


Рисунок 2.12. Последовательность предобработки данных

2.5. Выводы к главе 2

Дан подробный анализ содержимого выбранных в предыдущей главе БД.

Установлено значение меток БД PTB-XL в соответствии с медицинским описанием и определена их структура.

Составлена таблица соответствия между метками БД PTB-XL и БД LUDB.

Проведён анализ количества представителей каждой метки БД PTB-XL и LUDB.

На основе полученных сведений были сформированы СНД.

Описаны этапы предобработки и приведена схема, определяющая наличие этих этапов и последовательность их применения.

3. ПРОВЕДЕНИЕ ЭКСПЕРИМЕНТОВ И АНАЛИЗ РЕЗУЛЬТАТОВ

3.1. Описание выбранной модели

В качестве модели машинного обучения, как уже говорилось, выбрана свёрточная ИНС CNN, в силу её распространённости в подобных задачах классификации, невысокой требовательности к качеству данных и возможности тонкой настройке параметров.

Для решения поставленных в работе задач необходимо сравнить значимость каждого типа предобработки данных. Для этого надо создать одинаковые условия при работе с каждым подготовленным набором.

В работе использована ИНС CNN с архитектурой «LeNet» и дополнительным dropout слоем, размещённым между полносвязными, для уменьшения переобучения модели [40]. Согласно архитектуре «LeNet», в ИНС ещё будут присутствовать свёрточные и полносвязные слои, а также слои субдискретизации.

Свёрточный (convolution) слой осуществляет последовательное преобразование каждого фрагмента сигнала. Размер этого фрагмента определяется размером ядра свёртки, с которым происходит поэлементное произведение каждого фрагмента. Шаг фрагментации определяется как параметр, и в данном случае он равен единице. Периодичность признаков непостоянная, и чтобы не пропустить важную деталь, шаг нужно делать максимально маленьким.

Слой субдискретизации (pooling) используется для уплотнения признаков. Таким образом, уменьшается признаковое пространство и упрощается полносвязный блок сети, тем самым ускоряется процесс обучения модели и работа финальной решающей функции.

Слой исключения (dropout) отключает некоторый процент нейронов на каждой итерации в процессе обучения, снижая взаимонастройку нейронов и, как следствие, переобученность модели.

Полносвязный (dense) слой – это слой, непосредственно восстанавливающий зависимость между признаками и классами.

В таблицах 3.1–3.2 приведено описание настроек ИНС CNN сети для одномерного и двумерного входов соответственно. Под одномерным входом понимается вектор значений, составленный из двенадцати отрезков временных рядов. Под двумерным – матрица значений, а именно спектр сигнала, полученный из описанного ранее вектора с помощью непрерывного вейвлет-преобразования.

Таблица 3.1

Подробное описание модели для одномерного входа

Но- мер слоя	Название	Количе- ство филь- тров	Подби- раемых парамет- ров	Форма входа	Форма вы- хода	Шаг	Раз- мер ядра
1	Convolution	4	404	3636, 0	3636, 4	1	100
2	MaxPooling	–	0	3636, 4	1818, 4	–	–
3	Convolution	8	168	1818, 4	1818, 8	1	50
4	MaxPooling	–	0	1818, 8	909, 8	–	–
5	Convolution	16	656	909, 8	909, 16	1	5
6	MaxPooling	–	0	909, 16	454, 16	–	–
7	Convolution	32	2592	454, 16	454, 32	1	5
8	MaxPooling	–	0	454, 32	227, 32	–	–
9	Convolution	64	10304	227, 32	227, 64	1	5
10	Flatten	–	0	227, 64	14528	–	–
11	Dense	–	929856	14528	64	–	–
12	Dropout	–	0	64	64	–	–
13	Dense	–	195	64	3	–	–
Общее число параметров			944175				

Таблица 3.2

Подробное описание модели для двумерного входа

Но- мер слоя	Название	Количе- ство филь- тров	Подби- раемых парамет- ров	Форма входа	Форма вы- хода	Шаг	Раз- мер ядра
1	Convolution	4	40004	20, 3636, 0	20, 3636, 4	1	100
2	MaxPooling	–	0	20, 3636, 4	10, 1818, 4	–	–
3	Convolution	8	808	10, 1818, 4	10, 1818, 8	1	50
4	MaxPooling	–	0	10, 1818, 8	5, 909, 8	–	–
5	Convolution	16	3216	5, 909, 8	5, 909, 16	1	5
6	MaxPooling	–	0	5, 909, 16	2, 454, 16	–	–
7	Convolution	32	12832	2, 454, 16	2, 454, 32	1	5
8	MaxPooling	–	0	2, 454, 32	1, 227, 32	–	–
9	Convolution	64	51264	1, 227, 32	1, 227, 64	1	5
10	Flatten	–	0	1, 227, 64	14528	–	–
11	Dense	–	929856	14528	64	–	–
12	Dropout	–	0	64	64	–	–
13	Dense	–	195	64	3	–	–
Общее число параметров			1038175				

Наиболее важными параметрами, на которые стоит обратить внимание в случае повторного проведения эксперимента, являются размер ядра и количество фильтров. Теоретически, если размер ядра первой свёртки сделать примерно равным размерам объекта различения, то качество должно быть лучше. Количество же фильтров будет влиять на объём сохранённой информации после каждого процесса свёртки.

3.2. Выбор метрик оценки качества

В этой работе требуется решать задачу трёхклассовой классификации, поэтому такие метрики, как прецизионность (precision), полнота (recall), f1-score, специфичность (specificity), будут иметь по одному значению для каждого класса. Эти значения будем использовать для оценки качества сопоставления диагнозов.

В проводимом эксперименте использовать макро и микро усреднения классовых оценок малоинформативно, в виду отличия объёма классов и нецелесообразно, условиях всего трехклассовой классификации, поэтому для общей оценки значимости той или иной предобработки будем использовать метрику точности (ассурасу), добившись ненулевых значений метрик recall и precision компоновкой классов.

3.3. Результаты проведения экспериментов

Полные результаты с классовыми метриками precision, recall, f1-score, а также графиками, отображающими зависимость качества (ассурасу) и ошибки (loss) от эпохи обучения, приведены в приложении. Номера экспериментов в таблицах 3.3, 3.4, 3.5 соответствует номерам экспериментов в приложении.

В таблице 3.3 приведены результаты обучения ИНС с полным процессом предобработки данных.

Первое, что сразу же бросается в глаза – невысокое качество результата даже на тестовой выборке, не говоря уже про качество на валидационном наборе. Хотя подобная модель показывала близкое к единице качество в работах [13, 14], в нашем случае оно не превышает 0.75 по метрике ассигасу. Одна причина – данные, которые используются при обучении и тестировании. В представленных статьях и в большинстве других используются чистые размеченные данных, в которых одно обследование – один диагноз. Другая причина – тоже данные, но уже дело не в качестве, а в происхождении, в указанных работах тест и обучение происходят на одном наборе данных.

Сравнивая результаты на разных СНД, можно заметить, что качество на валидации от первого состава ко второму растёт, а вот от второго к третьему – падает, несмотря на улучшающиеся показатели качества на тесте. Из этого следует, что простой отбор диагнозов по количеству представителей в классе имеет место до определённого момента, после которого качество, наоборот, начинает падать.

При полном процессе предобработки с преобразованием сигнала в спектрограмму видно систематическое увеличение качества, что свидетельствует о некоторой пользе этого этапа.

Таблица 3.3

Результаты экспериментов часть 1

Этап предобработки		СНД 1				СНД 2				СНД 3			
1	Обрезка	+	+	+	+	+	+	+	+	+	+	+	+
2	Понижение размерности	+	+	+	+	+	+	+	+	+	+	+	+
3	Очистка от выбросов	+	+	+	+	+	+	+	+	+	+	+	+
4	Масштабирование	+		+		+		+		+		+	
5	Стандартизация		+		+		+		+		+		+
6	Получение спектра			+	+			+	+			+	+
Качество на тесте		0.63	0.64	0.67	0.70	0.67	0.67	0.65	0.72	0.69	0.73	0.72	0.76

Качество на валидации	0.39	0.30	0.38	0.43	0.53	0.37	0.64	0.61	0.51	0.58	0.54	0.55
Номер эксперимента	1	2	3	4	5	6	7	8	9	10	11	12

В таблице 3.4 приведены результаты проведения экспериментов без удаления начальных и конечных фрагментов сигнала.

Важность первого этапа предобработки по данным результатам оценить невозможно потому, что в процессе дальнейшего отбора обследований отсеивается значительная часть исходных данных, в которую включена большая часть рядов, очищенных от присутствующих краевых скачков. А вот по результатам работы с исходными данными и по количеству в них таких отклонений можно заметить, что с помощью первого этапа можно сохранить порядка двадцати процентов от исходного набора при условии, что дальше в этих рядах не будет обнаружено других отклонений на следующих этапах предобработки.

Таблица 3.4

Результаты экспериментов часть 2

Этап предобработки		СНД 1				СНД 2				СНД 3			
1	Обрезка												
2	Понижение размерности	+	+	+	+	+	+	+	+	+	+	+	+
3	Очистка от выбросов	+	+	+	+	+	+	+	+	+	+	+	+
4	Масштабирование	+		+		+		+		+		+	
5	Стандартизация		+		+		+		+		+		+
6	Получение спектра			+	+			+	+			+	+
Качество на тесте		0.60	0.63	0.69	0.70	0.67	0.71	0.69	0.74	0.70	0.71	0.69	0.77
Качество на валидации		0.46	0.41	0.43	0.44	0.57	0.56	0.63	0.62	0.61	0.56	0.54	0.58
Номер эксперимента		21	22	23	24	25	26	27	28	13	14	15	16

Для чистоты эксперимента были осуществлены попытки проведения экспериментов без понижения размерности и обрезки. Результаты приведены в таблице 3.5.

Из запланированных двенадцати получилось провести только два. Проблема возникла с вычислительными ресурсами. Их оказалось недостаточно для проведения масштабирования, стандартизации и непрерывного вейвлет-преобразования. Как видно из результатов, на меньшем составе всё-таки удалось обучить и протестировать модели, но качество в силу большой размерности получилось близким к качеству случайного классификатора. Последняя часть результатов показывает необходимость понижения размерности.

Отметить стоит и то, что большая размерность не позволяет произвести статистическое выявление выбросов, поскольку в силу природы сигнала средние оценки сильно смещаются. Именно поэтому третий шаг предобработки пропускается вместе со вторым.

Таблица 3.5

Результаты экспериментов часть 3													
Этап предобработки		СНД 1				СНД 2				СНД 3			
1	Обрезка												
2	Понижение размерности												
3	Очистка от выбросов												
4	Масштабирование	+		+		+		+		+		+	
5	Стандартизация		+		+		+		+		+		+
6	Получение спектра			+	+			+	+			+	+
Качество на тесте		—	—	—	—	—	—	—	—	0.55	0.55	—	—
Качество на валидации		—	—	—	—	—	—	—	—	0.50	0.50	—	—
Номер эксперимента		—	—	—	—	—	—	—	—	17	18	—	—

Анализ полученных результатов

Полученные результаты показывают наличие скачка качества при переходе от обучающего набора данных (PTB-XL) к контрольному (LUDB), что демонстрирует некоторую несостоятельность существующих на данный момент подходов к проведению, обработке и сбору результатов ЭКГ обследований.

Проведённые эксперименты демонстрируют, что способ сопоставления маркировок разных наборов данных требует особого внимания, и успеха всё-таки можно добиться, совершенствуя этот этап, ведь сопоставление диагнозов проводилось без привлечения экспертов в области кардиографии.

ИАД результатов электрофизиологических обследований типа ЭКГ показал необходимость предобработки данных перед использованием их в СИИ методом ИНС типа CNN и подбора этапов предобработки непосредственно для каждой БД в отдельности.

3.5. Вывод к главе 3

Описана архитектура ИНС типа CNN, проведён ряд экспериментов с применением ИАД методом ИНС патологий сердечной деятельности на основе ЭКГ.

Представлены результаты. По результатам даны пояснения и сделаны соответствующие выводы, о необходимости подбора БД на этапе их выбора, детального совмещения маркировок БД и подборе процесса предобработки для каждой БД индивидуально.

ЗАКЛЮЧЕНИЕ. ОСНОВНЫЕ РЕЗУЛЬТАТЫ

Изучены материалы предметной области, а именно некоторые медицинские и технические аспекты ЭКГ.

Проведён обзор существующих работ по теме ИАД и рассмотрены популярные модели ИАД.

В среде «Jupyter Notebook» реализован метод ИАД ЭКГ, а также каждый этап предобработки.

Проведён ряд экспериментов на основе реализованного метода ИАД путём машинного обучения ИНС в виде тринадцатислойной CNN с архитектурой «LeNet».

Обоснована необходимость детального совмещения маркировок, в случае использования нескольких БД.

Обоснована необходимость предварительной обработки исходных данных, для подготовки качественной обучающей выборки.

Получена оценка возможности совмещения нескольких наборов данных для формирования обучающего множества.

Исследования показали, что совместить разметки двух разных БД возможно, но процесс совмещения маркировок занимает не меньше времени, чем остальные манипуляции, а качество выполнения этапа предобработки сильно влияет на результат машинного обучения в целом.

Направление дальнейшей работы

В дальнейшем планируется на основе полученных результатов осуществить подготовку набора данных (БД) электрофизиологических исследований на основе ЭКГ для комплексного ИАД на базе машинного обучения ИНС типа CNN.

Список используемых источников

1. Lyon, A., Mincholé, A., Martínez, J. P., Laguna, P., & Rodriguez, B. (2018). Computational techniques for ECG analysis and interpretation in light of their contribution to medical advances. *Journal of The Royal Society Interface*, 15(138), 20170821. doi:10.1098/rsif.2017.0821
2. Zhai, X., Tin, C. (2018). Automated ECG Classification Using Dual Heartbeat Coupling Based on Convolutional Neural Network. *IEEE Access*, 6, 27465–27472. doi:10.1109/access.2018.2833841
3. Çınar, A., Tuncer, S. A. (2020). Classification of normal sinus rhythm, abnormal arrhythmia and congestive heart failure ECG signals using LSTM and hybrid CNN-SVM deep neural networks. *Computer Methods in Biomechanics and Biomedical Engineering*, 1–12. doi:10.1080/10255842.2020.1821192
4. Moody GB, Mark RG. The impact of the MIT-BIH Arrhythmia Database. *IEEE Eng in Med and Biol* 20(3):45-50 (May-June 2001). (PMID: 11446209)
5. ЭЛЕКТРОКАРДИОГРАФИЯ — Большая Медицинская Энциклопедия [Электронный ресурс]. URL: <https://бмэ.орг/index.php/ЭЛЕКТРОКАРДИОГРАФИЯ>
6. Электрокардиографические (ЭКГ) отведения [Электронный ресурс]. URL: <https://meduniver.com/Medical/Therapy/119.html>
7. Стандартные отведения Эйнтховена [Электронный ресурс]. URL: <https://biomolecula.ru/img/content/1574/05.treugolnik-Einthovena.png>
8. Усиленные отведения Гольдбергера [Электронный ресурс]. URL: <https://helpiks.org/helpiksorg/baza2/18046138346.files/image096.gif>
9. Грудные отведения Вильсона [Электронный ресурс]. URL: https://images.slideplayer.biz.tr/7/1957914/slides/slide_5.jpg
10. Схематичное изображение электрического поля сердца по схеме Уоллера [Электронный ресурс]. URL: <https://capta.ru/wp-content/uploads/ekg-nebu-3.jpg>
11. ЭКГ в норме [Электронный ресурс]. URL: https://meduniver.com/Medical/cardiology/Img/ekg_v_norme.jpg
12. Схема нормальной ЭКГ человека [Электронный ресурс]. URL: https://intfan.ru/wp-content/uploads/2020/12/resource_img_16090267925594.jpg
13. Дерево решений [Электронный ресурс]. URL: https://ru.wikipedia.org/wiki/Дерево_решений
14. Байесовский классификатор [Электронный ресурс]. URL: http://www.machinelearning.ru/wiki/index.php?title=Байесовский_классификатор
15. Машина опорных векторов [Электронный ресурс]. URL: <http://www.machinelearning.ru/wiki/index.php?title=SVM>
16. Свёрточная нейронная сеть [Электронный ресурс]. URL: https://ru.wikipedia.org/wiki/Свёрточная_нейронная_сеть
17. Метод ближайших соседей [Электронный ресурс]. URL: <http://www.machinelearning.ru/wiki/index.php?title=KNN>
18. Saini, I., Singh, D., Khosla, A. (2013). Delineation of ECG Wave Components Using K-Nearest Neighbor (KNN) Algorithm: ECG Wave Delineation Using KNN.

- 2013 10th International Conference on Information Technology: New Generations. doi:10.1109/itng.2013.76
19. Saini, R., Bindal, N., Bansal, P. (2015). Classification of heart diseases from ECG signals using wavelet transform and kNN classifier. International Conference on Computing, Communication & Automation. doi:10.1109/ccaa.2015.7148561
 20. Alodia Yusuf, S. A., Hidayat, R. (2019). MFCC Feature Extraction and KNN Classification in ECG Signals. 2019 6th International Conference on Information Technology, Computer and Electrical Engineering (ICITACEE). doi:10.1109/icitacee.2019.8904285
 21. Bouaziz, F., Boutana, D., Oulhadj, H. (2018). Diagnostic of ECG Arrhythmia using Wavelet Analysis and K-Nearest Neighbor Algorithm. 2018 International Conference on Applied Smart Systems (ICASS). doi:10.1109/icass.2018.8652020
 22. Saini, I., Singh, D., Khosla, A. (2013). QRS detection using K-Nearest Neighbor algorithm (KNN) and evaluation on standard ECG databases. Journal of Advanced Research, 4(4), 331–344. doi:10.1016/j.jare.2012.05.007
 23. Faziludeen, S., Sabiq, P. V. (2013). ECG beat classification using wavelets and SVM. 2013 IEEE CONFERENCE ON INFORMATION AND COMMUNICATION TECHNOLOGIES. doi:10.1109/cict.2013.6558206
 24. Kohli, N., Verma, N. K., Roy, A. (2010). SVM based methods for arrhythmia classification in ECG. 2010 International Conference on Computer and Communication Technology (ICCCT). doi:10.1109/iccct.2010.5640480
 25. Raj, S., Ray, K. C. (2017). ECG Signal Analysis Using DCT-Based DOST and PSO Optimized SVM. IEEE Transactions on Instrumentation and Measurement, 66(3), 470–478. doi:10.1109/tim.2016.2642758
 26. Li, Y., Pang, Y., Wang, J., Li, X. (2018). Patient-specific ECG classification by deeper CNN from generic to dedicated. Neurocomputing. doi:10.1016/j.neucom.2018.06.068
 27. Baloglu, U. B., Talo, M., Yildirim, O., Tan, R. S., & Acharya, U. R. (2019). Classification of Myocardial Infarction with Multi-Lead ECG Signals and Deep CNN. Pattern Recognition Letters. doi:10.1016/j.patrec.2019.02.016
 28. Xiong, Z., Stiles, M., Zhao, J. (2017). Robust ECG Signal Classification for the Detection of Atrial Fibrillation Using Novel Neural Networks. 2017 Computing in Cardiology Conference (CinC). doi:10.22489/cinc.2017.066-138
 29. Yin, W., Yang, X., Zhang, L., Oki, E. (2016). ECG Monitoring System Integrated with IR-UWB Radar Based on CNN. IEEE Access, 1–1. doi:10.1109/access.2016.2608777
 30. Ullah, A.; Rehman, S.u.; Tu, S.; Mehmood, R.M.; Fawad; Ehatisham-ul-haq, M. A. (2021). Hybrid Deep CNN Model for Abnormal Arrhythmia Detection Based on Cardiac ECG Signal doi:10.3390/s21030951
 31. Eltrass, A. S., Tayel, M. B., Ammar, A. I. (2021). A new automated CNN deep learning approach for identification of ECG congestive heart failure and arrhythmia using constant-Q non-stationary Gabor transform. Biomedical Signal Processing and Control, 65, 102326. doi:10.1016/j.bspc.2020.102326

32. Salem, M., Taheri, S., & Yuan, J.-S. (2018). ECG Arrhythmia Classification Using Transfer Learning from 2- Dimensional Deep CNN Features. 2018 IEEE Biomedical Circuits and Systems Conference (BioCAS). doi:10.1109/bio-cas.2018.8584808
33. Wagner, P., Strodthoff, N., Bousseljot, R.-D., Kreiseler, D., Lunze, F.I., Samek, W., Schaeffter, T. (2020), PTB-XL: A Large Publicly Available ECG Dataset. Scientific Data. doi:10.1038/s41597-020-0495-6
34. Kalyakulina, A.I., Yusipov, I.I., Moskalenko, V.A., Nikolskiy, A.V., Kosonogov, K.A., Osipov, G.V., Zolotykh, N.Yu., Ivanchenko, M.V.: LUDB: A New Open-Access Validation Tool for Electrocardiogram Delineation Algorithms, IEEE Access, vol. 8, pp. 186181-186190, 2020, doi:10.1109/ACCESS.2020.3029211
35. Общий состав данных PTB-XL [Электронный ресурс]. URL: https://media.springernature.com/full/springer-static/image/art%3A10.1038%2Fs41597-020-0495-6/MediaObjects/41597_2020_495_Fig1_HTML.png?as=webp
36. Состав классов PTB-XL [Электронный ресурс]. URL: https://media.springernature.com/full/springer-static/image/art%3A10.1038%2Fs41597-020-0495-6/MediaObjects/41597_2020_495_Fig5_HTML.png?as=webp
37. Bagirathan, A., Selvaraj, J., Gurusamy, A., & Das, H. (2020). Recognition of positive and negative valence states in children with autism spectrum disorder (ASD) using discrete wavelet transform (DWT) analysis of electrocardiogram signals (ECG). Journal of Ambient Intelligence and Humanized Computing. doi:10.1007/s12652-020-01985-1
38. Непрерывное wavelet преобразование / Хабр [Электронный ресурс]. URL: <https://habr.com/ru/post/103899/>
39. Smaoui, G., Young, A., & Abid, M. (2017). Single Scale CWT Algorithm for ECG Beat Detection for a Portable Monitoring System. Journal of Medical and Biological Engineering, 37(1), 132–139. doi:10.1007/s40846-016-0212-2
40. Dropout — метод решения проблемы переобучения в нейронных сетях / Блог компании Wunder Fund / Хабр [Электронный ресурс]. URL: <https://habr.com/ru/company/wunderfund/blog/330814/>
41. Яковлев А.Н. Я 474 Введение в вейвлет-преобразования: Учеб. пособие. — Новосибирск: Изд-во НГТУ, 2003. — 104 с. ISBN 5-7782-0405-1 УДК 621.372(075.8)+004.92(075.8)
42. Кардиология. Заболевания сердца детей и взрослых [Электронный ресурс]. Дата обращения: июнь 2021. URL: <https://meduniver.com/Medical/cardiologia/>
43. Профессиональный информационно-аналитический ресурс, посвященный машинному обучению, распознаванию образов и интеллектуальному анализу данных [Электронный ресурс]. Дата обращения: июнь 2021. URL: <http://www.machinelearning.ru/>
44. PyWavelets Documentation [Электронный ресурс]. Дата обращения: июнь 2021. URL: <https://buildmedia.readthedocs.org/media/pdf/pywavelets/latest/py-wavelets.pdf>


Приложения


Приложение. Результаты экспериментов.

Номер каждого эксперимента соответствует номеру, указанному в таблицах 3.3, 3.4, 3.5.

Полными результатами одного эксперимента являются графики изменения точности (accuracy) и ошибки (loss) в зависимости от эпохи обучения, классовые метрики точности (precision), полноты (recall) и f1-меры (f1-score), макро и микро усреднения классовых метрик, метрика точности (accuracy) и поэлементный состав (support).



Эксперимент 1





Validate				
	precision	recall	f1-score	support
0	0.46	0.62	0.53	53
1	0.74	0.24	0.37	94
2	0.02	1.00	0.04	1
accuracy			0.39	148
macro avg	0.41	0.62	0.31	148
weighted avg	0.64	0.39	0.42	148
Test				
	precision	recall	f1-score	support
0	0.67	0.59	0.63	772
1	0.38	0.34	0.36	283
2	0.62	0.72	0.67	751
accuracy			0.61	1806
macro avg	0.56	0.55	0.55	1806
weighted avg	0.61	0.61	0.60	1806



Эксперимент 2



Validate				
	precision	recall	f1-score	support
0	0.51	0.62	0.56	53
1	0.61	0.12	0.20	94
2	0.02	1.00	0.03	1
accuracy			0.30	148
macro avg	0.38	0.58	0.26	148
weighted avg	0.57	0.30	0.33	148
Test				
	precision	recall	f1-score	support

0	0.75	0.61	0.68	772
1	0.41	0.25	0.31	283
2	0.61	0.81	0.70	751
accuracy			0.64	1806
macro avg	0.59	0.56	0.56	1806
weighted avg	0.64	0.64	0.63	1806


Эксперимент 3




Validate				
	precision	recall	f1-score	support
0	0.43	0.81	0.57	53
1	0.86	0.13	0.22	94

2	0.03	1.00	0.06	1
accuracy			0.38	148
macro avg	0.44	0.65	0.28	148
weighted avg	0.70	0.38	0.34	148
Test				
	precision	recall	f1-score	support
0	0.72	0.72	0.72	772
1	0.53	0.29	0.38	283
2	0.66	0.78	0.72	751
accuracy			0.67	1806
macro avg	0.64	0.59	0.60	1806
weighted avg	0.67	0.67	0.66	1806



Эксперимент 4





Validate				
	precision	recall	f1-score	support
0	0.54	0.68	0.60	53
1	0.81	0.28	0.41	94
2	0.02	1.00	0.04	1
accuracy			0.43	148
macro avg	0.46	0.65	0.35	148
weighted avg	0.71	0.43	0.48	148
Test				
	precision	recall	f1-score	support
0	0.83	0.67	0.74	772
1	0.45	0.47	0.46	283
2	0.68	0.81	0.74	751
accuracy			0.70	1806
macro avg	0.65	0.65	0.65	1806
weighted avg	0.71	0.70	0.70	1806



Эксперимент 5



Validate				
	precision	recall	f1-score	support
0	0.52	0.76	0.61	62
1	0.78	0.39	0.52	97
2	0.00	0.00	0.00	1
accuracy			0.53	160
macro avg	0.43	0.38	0.38	160
weighted avg	0.67	0.53	0.55	160
Test				
	precision	recall	f1-score	support
0	0.73	0.77	0.75	698

1	0.58	0.60	0.59	331
2	0.61	0.52	0.56	322
accuracy			0.67	1351
macro avg	0.64	0.63	0.63	1351
weighted avg	0.67	0.67	0.67	1351


Эксперимент 6




Validate				
	precision	recall	f1-score	support
0	0.49	0.63	0.55	62
1	0.59	0.21	0.31	97

2	0.00	0.00	0.00	1
accuracy			0.37	160
macro avg	0.36	0.28	0.29	160
weighted avg	0.55	0.37	0.40	160
Test				
	precision	recall	f1-score	support
0	0.79	0.77	0.78	698
1	0.60	0.43	0.50	331
2	0.51	0.69	0.59	322
accuracy			0.67	1351
macro avg	0.63	0.63	0.62	1351
weighted avg	0.68	0.67	0.66	1351



Эксперимент 7





Validate				
	precision	recall	f1-score	support
0	0.56	0.79	0.66	62
1	0.80	0.55	0.65	97
2	0.00	0.00	0.00	1
accuracy			0.64	160
macro avg	0.46	0.45	0.44	160
weighted avg	0.71	0.64	0.65	160
Test				
	precision	recall	f1-score	support
0	0.74	0.76	0.75	698
1	0.51	0.78	0.62	331
2	0.71	0.28	0.40	322
accuracy			0.65	1351
macro avg	0.65	0.61	0.59	1351
weighted avg	0.68	0.65	0.64	1351



Эксперимент 8



Validate				
	precision	recall	f1-score	support
0	0.64	0.79	0.71	62
1	0.81	0.49	0.62	97
2	0.00	0.00	0.00	1
accuracy			0.61	160
macro avg	0.48	0.43	0.44	160
weighted avg	0.74	0.61	0.65	160
Test				
	precision	recall	f1-score	support
0	0.82	0.80	0.81	698

1	0.64	0.66	0.65	331
2	0.61	0.63	0.62	322
accuracy			0.72	1351
macro avg	0.69	0.70	0.69	1351
weighted avg	0.73	0.72	0.73	1351


Эксперимент 9




Validate				
	precision	recall	f1-score	support
0	0.60	0.69	0.65	88
1	0.70	0.32	0.44	88
2	0.00	0.00	0.00	0

accuracy			0.51	176
macro avg	0.43	0.34	0.36	176
weighted avg	0.65	0.51	0.54	176
Test				
	precision	recall	f1-score	support
0	0.76	0.79	0.78	708
1	0.66	0.48	0.55	302
2	0.58	0.67	0.62	302
accuracy			0.69	1312
macro avg	0.66	0.65	0.65	1312
weighted avg	0.69	0.69	0.69	1312



Эксперимент 10





Validate				
	precision	recall	f1-score	support
0	0.63	0.73	0.68	88
1	0.70	0.43	0.54	88
2	0.00	0.00	0.00	0
accuracy			0.58	176
macro avg	0.45	0.39	0.40	176
weighted avg	0.67	0.58	0.61	176
Test				
	precision	recall	f1-score	support
0	0.76	0.88	0.82	708
1	0.67	0.56	0.61	302
2	0.71	0.57	0.63	302
accuracy			0.73	1312
macro avg	0.71	0.67	0.69	1312
weighted avg	0.73	0.73	0.73	1312



Эксперимент 11



Validate				
	precision	recall	f1-score	support
0	0.59	0.80	0.68	88
1	0.76	0.28	0.41	88
2	0.00	0.00	0.00	0
accuracy			0.54	176
macro avg	0.45	0.36	0.36	176
weighted avg	0.68	0.54	0.55	176
Test				
	precision	recall	f1-score	support
0	0.75	0.84	0.79	708

1	0.73	0.45	0.56	302
2	0.62	0.69	0.65	302
accuracy			0.72	1312
macro avg	0.70	0.66	0.67	1312
weighted avg	0.72	0.72	0.71	1312


Эксперимент 12




Validate				
	precision	recall	f1-score	support
0	0.65	0.62	0.64	88
1	0.67	0.47	0.55	88
2	0.00	0.00	0.00	0

accuracy			0.55	176
macro avg	0.44	0.36	0.40	176
weighted avg	0.66	0.55	0.59	176
Test				
	precision	recall	f1-score	support
0	0.87	0.82	0.84	708
1	0.65	0.71	0.68	302
2	0.66	0.69	0.68	302
accuracy			0.76	1312
macro avg	0.73	0.74	0.73	1312
weighted avg	0.77	0.76	0.77	1312



Эксперимент 13





Validate				
	precision	recall	f1-score	support
0	0.68	0.77	0.72	87
1	0.72	0.44	0.55	81
2	0.00	0.00	0.00	0
accuracy			0.61	168
macro avg	0.47	0.40	0.42	168
weighted avg	0.70	0.61	0.64	168
Test				
	precision	recall	f1-score	support
0	0.80	0.75	0.77	726
1	0.55	0.64	0.59	293
2	0.63	0.62	0.62	289
accuracy			0.70	1308
macro avg	0.66	0.67	0.66	1308
weighted avg	0.71	0.70	0.70	1308



Эксперимент 14



Validate				
	precision	recall	f1-score	support
0	0.68	0.62	0.65	87
1	0.59	0.49	0.54	81
2	0.00	0.00	0.00	0
accuracy			0.56	168
macro avg	0.42	0.37	0.39	168
weighted avg	0.63	0.56	0.59	168
Test				
	precision	recall	f1-score	support
0	0.81	0.75	0.78	726

1	0.56	0.78	0.65	293
2	0.71	0.57	0.63	289
accuracy			0.71	1308
macro avg	0.69	0.70	0.69	1308
weighted avg	0.73	0.71	0.72	1308


Эксперимент 15




Validate				
	precision	recall	f1-score	support
0	0.59	0.87	0.70	87
1	0.75	0.19	0.30	81
2	0.00	0.00	0.00	0

accuracy			0.54	168
macro avg	0.45	0.35	0.33	168
weighted avg	0.67	0.54	0.51	168
Test				
	precision	recall	f1-score	support
0	0.73	0.87	0.79	726
1	0.71	0.33	0.45	293
2	0.55	0.60	0.57	289
accuracy			0.69	1308
macro avg	0.66	0.60	0.61	1308
weighted avg	0.69	0.69	0.67	1308



Эксперимент 16





Validate				
	precision	recall	f1-score	support
0	0.67	0.67	0.67	87
1	0.65	0.48	0.55	81
2	0.00	0.00	0.00	0
accuracy			0.58	168
macro avg	0.44	0.38	0.41	168
weighted avg	0.66	0.58	0.61	168
Test				
	precision	recall	f1-score	support
0	0.84	0.82	0.83	726
1	0.68	0.76	0.72	293
2	0.70	0.65	0.68	289
accuracy			0.77	1308
macro avg	0.74	0.74	0.74	1308
weighted avg	0.77	0.77	0.77	1308



Эксперимент 17



Validate				
	precision	recall	f1-score	support
0	0.50	1.00	0.67	92
1	0.00	0.00	0.00	91
accuracy			0.50	183
macro avg	0.25	0.50	0.33	183
weighted avg	0.25	0.50	0.34	183
Test				
	precision	recall	f1-score	support
0	0.55	1.00	0.71	771

1	0.00	0.00	0.00	295
2	0.00	0.00	0.00	346
accuracy			0.55	1412
macro avg	0.18	0.33	0.24	1412
weighted avg	0.30	0.55	0.39	1412


Эксперимент 18




Validate				
	precision	recall	f1-score	support
0	0.50	1.00	0.67	92
1	0.00	0.00	0.00	91

accuracy			0.50	183
macro avg	0.25	0.50	0.33	183
weighted avg	0.25	0.50	0.34	183
Test				
	precision	recall	f1-score	support
0	0.55	1.00	0.71	771
1	0.00	0.00	0.00	295
2	0.00	0.00	0.00	346
accuracy			0.55	1412
macro avg	0.18	0.33	0.24	1412
weighted avg	0.30	0.55	0.39	1412



Эксперимент 21





Validate				
	precision	recall	f1-score	support
0	0.49	0.69	0.58	52
1	0.78	0.32	0.46	87
2	0.03	1.00	0.06	1
accuracy			0.46	140
macro avg	0.43	0.67	0.36	140
weighted avg	0.67	0.46	0.50	140
Test				
	precision	recall	f1-score	support
0	0.66	0.62	0.64	765
1	0.39	0.39	0.39	277
2	0.62	0.66	0.64	755
accuracy			0.60	1797
macro avg	0.56	0.56	0.56	1797
weighted avg	0.60	0.60	0.60	1797



Эксперимент 22



Validate				
	precision	recall	f1-score	support
0	0.58	0.73	0.65	52
1	0.82	0.21	0.33	87
2	0.02	1.00	0.04	
accuracy			0.41	140
macro avg	0.47	0.65	0.34	140
weighted avg	0.73	0.41	0.45	140
Test				
	precision	recall	f1-score	support

0	0.75	0.60	0.67	765
1	0.39	0.24	0.30	277
2	0.60	0.80	0.68	755
accuracy			0.63	1797
macro avg	0.58	0.55	0.55	1797
weighted avg	0.63	0.63	0.62	1797


Эксперимент 23




Validate				
	precision	recall	f1-score	support
0	0.48	0.92	0.63	52
1	0.92	0.13	0.22	87

2	0.04	1.00	0.07	1
accuracy			0.43	140
macro avg	0.48	0.68	0.31	140
weighted avg	0.75	0.43	0.37	140
Test				
	precision	recall	f1-score	support
0	0.69	0.77	0.73	765
1	0.48	0.25	0.33	277
2	0.71	0.76	0.74	755
accuracy			0.69	1797
macro avg	0.63	0.59	0.60	1797
weighted avg	0.67	0.69	0.67	1797



Эксперимент 24





Validate				
	precision	recall	f1-score	support
0	0.54	0.73	0.62	52
1	0.73	0.25	0.38	87
2	0.03	1.00	0.05	1
accuracy			0.44	14
macro avg	0.43	0.66	0.35	140
weighted avg	0.65	0.44	0.46	140
Test				
	precision	recall	f1-score	support
0	0.83	0.64	0.72	765
1	0.47	0.50	0.49	277
2	0.68	0.83	0.75	755
accuracy			0.70	1797
macro avg	0.66	0.66	0.65	1797
weighted avg	0.71	0.70	0.70	1797



Эксперимент 25



Validate				
	precision	recall	f1-score	support
0	0.52	0.82	0.64	61
1	0.77	0.41	0.54	90
2	0.00	0.00	0.00	1
accuracy			0.57	152
macro avg	0.43	0.41	0.39	152
weighted avg	0.67	0.57	0.57	152
Test				
	precision	recall	f1-score	support
0	0.71	0.82	0.76	710

1	0.54	0.55	0.55	319
2	0.70	0.45	0.55	318
accuracy			0.67	1347
macro avg	0.65	0.60	0.62	1347
weighted avg	0.67	0.67	0.66	1347


Эксперимент 26




Validate				
	precision	recall	f1-score	support
0	0.56	0.82	0.67	61
1	0.81	0.39	0.53	90

2	0.00	0.00	0.00	1
accuracy			0.56	152
macro avg	0.46	0.40	0.40	152
weighted avg	0.71	0.56	0.58	152
Test				
	precision	recall	f1-score	support
0	0.76	0.83	0.80	710
1	0.62	0.62	0.62	319
2	0.65	0.52	0.57	318
accuracy			0.71	1347
macro avg	0.68	0.66	0.66	1347
weighted avg	0.70	0.71	0.70	1347



Эксперимент 27





Validate				
	precision	recall	f1-score	support
0	0.55	0.87	0.67	61
1	0.88	0.31	0.46	90
2	0.04	1.00	0.08	1
accuracy			0.63	152
macro avg	0.49	0.73	0.40	152
weighted avg	0.74	0.54	0.54	152
Test				
	precision	recall	f1-score	support
0	0.78	0.79	0.79	710
1	0.65	0.47	0.54	319
2	0.54	0.68	0.60	318
accuracy			0.69	1347
macro avg	0.66	0.65	0.64	1347
weighted avg	0.69	0.69	0.68	1347

Эксперимент 28



Validate				
	precision	recall	f1-score	support
0	0.64	0.77	0.70	61
1	0.80	0.53	0.64	90
2	0.00	0.00	0.00	1
accuracy			0.62	152
macro avg	0.48	0.43	0.45	152
weighted avg	0.73	0.62	0.66	152
Test				
	precision	recall	f1-score	support
0	0.83	0.79	0.81	710

1	0.63	0.72	0.67	319
2	0.67	0.64	0.66	318
accuracy			0.74	1347
macro avg	0.71	0.72	0.71	1347
weighted avg	0.75	0.74	0.74	1347